

Bia

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA KHOA HỌC VÀ CÔNG NGHỆ GIÁO DỤC



HỌC PHẦN: KHAI THÁC THÔNG TIN ĐA PHƯƠNG TIỆN – AC2030

BÁO CÁO BÀI TẬP LỚN CUỐI KỲ

Giảng viên hướng dẫn: PGS. TS. Lê Thị Lan

Mã lớp: 169992

Đề tài:

CV Topic 1 - Nhận dạng cảm xúc của người học khi tham gia lớp học online

Các thành viên trong nhóm:

- Trần Thế Quang - 202411991 (Nhóm trưởng)
- Nguyễn Công Thắng - 202412003

Hà Nội, tháng 07 năm 2026

PHÂN CHIA CÔNG VIỆC

Thành viên	Nhiệm vụ chi tiết	Sản phẩm đầu ra
Nguyễn Công Thắng - 202412003	1. Tiền xử lý: Lọc tập FairFace SEA, cân bằng dữ liệu, viết code CLAHE. 2. Dashboard: Code vẽ Dashboard (Pie Chart, Timeline, Scatter Plot). 3. Đánh giá: Vận hành file kiểm thử, xuất biểu đồ (ma trận nhầm lẫn, training). 4. Học thuật: Soạn thảo Chương 3-6, thiết kế Slide thuyết trình.	- Bộ dữ liệu (Train/Test) - Hàm <code>_preprocess_face</code> - Code Dashboard - Biểu đồ (<code>confusion_matrix</code>, <code>training_curve</code>) - File báo cáo, Slide PowerPoint
Trần Thế Quang - 202411991	1. Huấn luyện: Linear Probing (đóng băng backbone, cấu hình Loss/Optimizer, 15 Epochs). 2. Toán học: Thuật toán chiếu không gian con, sửa lỗi remap nhãn (8 lớp sang 6 lớp). 3. Webcam: Kết nối OpenCV, Frame Skipping (tăng FPS 10 lên 30). 4. Theo dõi: Lập trình Temporal Smoothing, Centroid Tracking.	- File trọng số <code>models/finetuned.pt</code> - Code chuẩn hóa nhãn - Vòng lặp Webcam tối ưu - Hàm <code>predict_emotion</code>, <code>_get_face_key</code>

Bạn có thể chèn bảng này trực tiếp vào phần **Phân chia công việc** trong báo cáo để tăng tính chuyên nghiệp và rõ ràng.

CHƯƠNG 1: TỔNG QUAN

CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN FER TRONG E-LEARNING

1.1. Phát biểu bài toán Nhận dạng Cảm xúc Khuôn mặt (Facial Emotion Recognition - FER)

1.1.1. Khái niệm khoa học dưới góc nhìn Thị giác máy tính (Computer Vision)

Dưới góc nhìn của khoa học Thị giác máy tính, Nhận dạng Cảm xúc Khuôn mặt (FER) thực chất là bài toán phân loại hình ảnh dựa trên các thuật toán thông minh. Máy tính sẽ nhận đầu vào là một bức ảnh tĩnh hoặc một khung hình từ camera, sau đó phân tích các đặc điểm trên mặt để đưa ra dự đoán về cảm xúc tương ứng (như vui, buồn, bình thường, tức giận...).

Để làm được việc này, một hệ thống nhận dạng cảm xúc tiêu chuẩn sẽ chạy qua 4 bước cơ bản sau [1]:

1. **Phát hiện khuôn mặt (Face Detection):** Máy tính quét bức ảnh thô đầu vào để tìm ra vị trí chính xác của khuôn mặt và vẽ một khung vuông (Bounding Box) bao quanh, giúp loại bỏ toàn bộ phần nền nhiễu xung quanh.
2. **Tiền xử lý (Preprocessing):** Máy tính tiến hành xoay ảnh cho thẳng (nếu người học đang bị nghiêng đầu), đưa ảnh về một kích cỡ chuẩn đồng nhất và tự động điều chỉnh độ sáng tối để các chi tiết cơ mặt hiển thị rõ nét nhất.
3. **Trích xuất đặc trưng (Feature Extraction):** Đây là bước cốt lõi. Máy tính sẽ tìm kiếm và lưu lại các thông tin quyết định biểu cảm trên gương mặt như hình dáng mắt, độ nhíu chân mày hay độ mở của khóe miệng. Hãy tưởng tượng bước này giống như một họa sĩ vẽ ký họa, chỉ giữ lại những nét vẽ quan trọng nhất quyết định thần thái biểu cảm.
4. **Phân lớp cảm xúc (Classification):** Sử dụng mạng nơ-ron thông minh để so sánh các đặc trưng vừa trích xuất được với kho dữ liệu mẫu đã học, từ đó đưa ra nhãn cảm xúc cuối cùng của người học.



Hình 1: Các giai đoạn của quy trình nhận diện khuôn mặt.

1.1.2. Mối liên hệ với Khai thác thông tin đa phương tiện (Multimedia Information Retrieval)

Khai thác thông tin đa phương tiện là việc tìm kiếm, phân tích dữ liệu tổng hợp từ nhiều nguồn khác nhau như văn bản, âm thanh, hình ảnh và video. Luồng video webcam của người học khi học online chính là một nguồn dữ liệu đa phương tiện rất giàu thông tin, bao gồm hai chiều quan trọng: Không gian và Thời gian

Hệ thống sẽ ghi nhận cảm xúc của người học kèm theo mốc thời gian thực tế (timestamp). Nhờ việc lập chỉ mục đồng bộ này, giáo viên hoặc hệ thống quản lý có thể dễ dàng truy xuất các thông tin vô cùng hữu ích như: "*Tìm những đoạn học sinh bị bối rối dài hơn 5 giây trong bài giảng*" hoặc "*Thống kê xem học sinh có bị mệt mỏi quá 20% tổng thời lượng buổi học không*" để giáo viên kịp thời điều chỉnh cách giảng dạy.

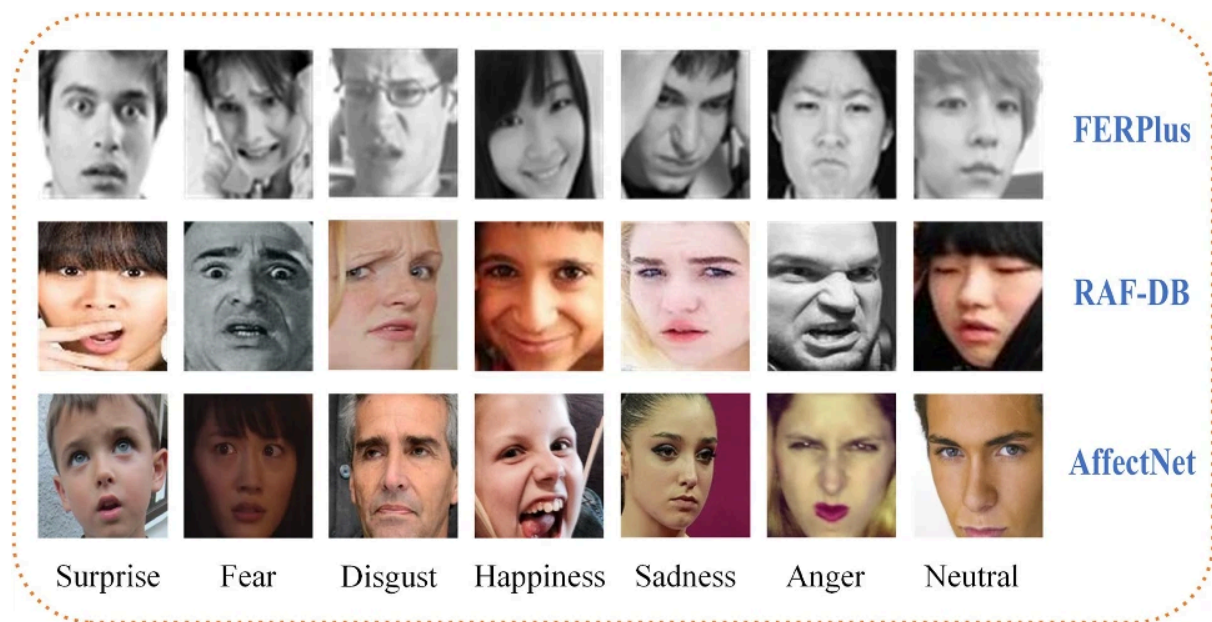
1.1.3. Các mô hình biểu diễn cảm xúc tiêu chuẩn

Để máy tính hiểu được cảm xúc, chúng ta cần phân loại cảm xúc theo các mô hình chuẩn:

- **Mô hình 6 cảm xúc cơ bản của Paul Ekman:** Gồm *Angry (Tức giận)*, *Disgust (Ghê tởm)*, *Fear (Sợ hãi)*, *Happy (Vui vẻ)*, *Sad (Buồn bã)* và *Surprise (Ngạc nhiên)*. Đây là các biểu cảm tự nhiên mang tính phổ quát, giống nhau ở mọi chủng tộc và nền văn hóa trên thế giới.
- **Mô hình 8 lớp:** Bổ sung thêm hai nhãn quan trọng là *Contempt (Khinh bỉ)* và *Neutral (Trung tính)*.

Trong đó, trạng thái **Neutral (Trung tính - gương mặt bình thường)** đặc biệt quan trọng trong giáo dục trực tuyến vì nó chiếm tới hơn 70% thời gian học tập. Trạng thái này đóng vai trò làm "mốc nền" để hệ thống so sánh. Khi học sinh cười hay nhíu mày, AI sẽ đo độ lệch so với trạng thái bình thường này để nhận diện cảm xúc chính xác hơn, tránh lỗi nhận nhầm do khuôn mặt tự nhiên bẩm sinh của mỗi người khác nhau (ví dụ: có người bẩm sinh khóe mắt hơi trễ trông giống đang buồn, hoặc cung mày hẹp trông giống đang giận dữ).

Trong mô hình này, nhóm lựa chọn 6 cảm xúc trong 8 cảm xúc của mô hình gốc do loại bỏ Fear (gộp vào Disgust $\approx$ khó hiểu) và Contempt (không phổ biến trong môi trường học online), giữ lại: Anger, Disgust, Happiness, Neutral, Sadness, Surprise.



Hình 2: Biểu hiện cảm xúc trong các bộ dữ liệu FERPlus, RAF-DB và AffectNet [3]

1.2. Vai trò và ý nghĩa thực tiễn trong Giáo dục trực tuyến (E-Learning)

1.2.1. Đo lường mức độ tương tác trực quan

Học online có điểm yếu lớn là thầy cô và học sinh bị ngăn cách bởi màn hình, thầy cô rất khó biết học sinh có đang tập trung hay không. Công nghệ FER đóng vai trò như một giác quan kỹ thuật số giúp lượng hóa độ tập trung tinh thần của người học thành 3 cấp độ:

- **Tương tác tích cực (Tập trung cao):** Học sinh nhìn thẳng màn hình, mắt mở to tập trung, đầu hơi hướng về phía trước và có thể hơi giãn cơ mặt nhẹ (biểu cảm vui vẻ nhẹ) thể hiện sự hào hứng và tiếp thu tốt bài giảng.
- **Tương tác thụ động (Tập trung bình thường):** Gương mặt học sinh giữ trạng thái bình thường (**Neutral**), các cơ mặt thư giãn nhưng ánh mắt và hướng đầu vẫn nhìn ổn định vào slide bài giảng để tiếp nhận thông tin.
- **Mất tương tác (Loãng):** Học sinh quay đi chỗ khác liên tục, cúi gập đầu xuống bàn làm việc riêng, hoặc nhắm mắt quá lâu, gương mặt lộ rõ vẻ chán nản, mệt mỏi.

1.2.2. Nhận diện trạng thái nhận thức bối rối

Sự bối rối xuất hiện khi học sinh gặp phải kiến thức mới lạ hoặc bài tập khó. Trong tâm lý giáo dục, đây là "khoảnh khắc vàng": nếu giáo viên phát hiện kịp thời để giảng lại thì học sinh sẽ hiểu rất sâu; ngược lại, nếu để bối rối kéo dài mà không được giải đáp, học sinh sẽ dễ chán nản và từ bỏ học tập.

Khi hệ thống phát hiện nhiều học sinh cùng biểu hiện bối rối ở một slide, nó sẽ báo giảng viên giảng lại kỹ hơn, hoặc tự động gợi ý thêm tài liệu giải thích dễ hiểu cho học sinh nếu học tự do trên hệ thống.

1.3. Các thách thức kỹ thuật đặc thù trong thực tế môi trường E-Learning

1.3.1. Sự biến động phức tạp của môi trường xung quanh

Góc học tập tại nhà chứa nhiều yếu tố ánh sáng và chuyển động gây nhiễu cho AI [3]:

- **Ánh sáng cực đoan:** Học sinh ngồi ngược sáng (gần cửa sổ ban ngày) khiến mặt bị tối đen; học ban đêm tắt đèn phòng khiến mặt bị lóa ánh sáng xanh từ màn hình; hoặc đèn bàn đặt một bên tạo bóng đổ che khuất nửa mặt. Sự biến động này làm thay đổi cấu trúc sáng tối trên mặt, gây khó khăn lớn cho AI.
- **Hậu cảnh nhiễu động:** Phía sau có người đi qua đi lại hoặc đồ vật lộn xộn khiến máy tính dễ nhận diện nhầm khuôn mặt.

1.3.2. Sự đa dạng về nhân trắc học và các yếu tố che khuất

Khuôn mặt mỗi người một khác và học sinh thường có nhiều hành động tự nhiên che khuất mặt [3]:

- **Yếu tố che khuất:** Học sinh đeo kính cận bị lóa ánh sáng màn hình trên tròng kính che mất mắt; tóc mái dài che lông mày; hoặc thói quen tự nhiên đưa tay chống cằm, che miệng khi suy nghĩ làm mất đi thông tin nửa dưới mặt.
- **Góc đầu thay đổi:** Học sinh không ngồi yên nhìn thẳng mà thường cúi đầu chép bài, ngửa đầu, hoặc xoay nghiêng mặt để đọc sách bên cạnh. Khi góc nghiêng đầu lớn hơn 30 độ, cấu trúc đối xứng khuôn mặt bị phá vỡ, làm giảm sút độ chính xác của mô hình AI.

CHƯƠNG 2: CÁC PHƯƠNG PHÁP TRUYỀN THỐNG


CHƯƠNG 2: CÁC PHƯƠNG PHÁP TRUYỀN THỐNG

2.1. Quy trình xử lý hai giai đoạn độc lập

Trong kỷ nguyên trước khi học sâu (Deep Learning) bùng nổ, các hệ thống nhận dạng cảm xúc khuôn mặt (FER) truyền thống đều vận hành theo một kiến trúc dạng ống dẫn tuần tự (pipeline). Đặc trưng lớn nhất của phương pháp này là sự phân tách hoàn toàn giữa hai giai đoạn: trích chọn đặc trưng thủ công (Hand-crafted Feature Extraction) và phân lớp học máy (Machine Learning Classification).

Quy trình này diễn ra theo các bước độc lập nối tiếp nhau:

1. **Đầu vào:** Luồng hình ảnh thô từ camera sau khi phát hiện và cắt ra vùng khuôn mặt.
2. **Giai đoạn 1 - Trích chọn đặc trưng thủ công:** Con người tự thiết kế ra các bộ lọc hoặc công thức toán học để ép ma trận ảnh từ hàng nghìn điểm ảnh về một danh sách các con số cô đọng (gọi là vector đặc trưng). Máy tính chỉ làm nhiệm vụ tính toán theo công thức có sẵn này chứ không tự học cách tìm đặc trưng.
3. **Giai đoạn 2 - Phân lớp học máy:** Đưa vector đặc trưng thu được ở Giai đoạn 1 vào một thuật toán học máy cổ điển độc lập có cấu trúc nông (Classifier with shallow structure) để gán nhãn cảm xúc.
4. **Đầu ra:** Nhãn cảm xúc dự đoán cuối cùng của người học (ví dụ: Happy, Sad, Neutral...) được hệ thống đưa ra sau quá trình phân lớp, phục vụ cho việc hiển thị trực quan hoặc lưu trữ thống kê




Hình 3: Minh họa quy trình Học máy sử dụng phương pháp trích xuất đặc trưng thủ công.

Hạn chế kiến trúc: Vì hai giai đoạn này hoạt động hoàn toàn tách biệt, hiệu năng của cả hệ thống phụ thuộc hoàn toàn vào chất lượng của bộ trích chọn đặc trưng ở Giai đoạn 1. Nếu giai đoạn trích chọn đặc trưng bị nhiễu (do ánh sáng hoặc góc nghiêng), bộ phân lớp ở Giai đoạn 2 dù mạnh đến đâu cũng sẽ đưa ra kết quả sai lệch[4].

2.2. Các phương pháp trích chọn đặc trưng thủ công phổ biến

Trong các cách tiếp cận truyền thống, để máy tính hiểu được biểu cảm, người ta bắt buộc phải sử dụng các thuật toán toán học do con người tự thiết kế cứng bằng tay (Hand-crafted Features). Bốn phương pháp kinh điển nhất bao gồm:


1. **Đặc trưng hình học dựa trên Landmark:** Xác định tọa độ của các điểm mốc chuẩn trên mặt (như mắt, chân mày, viền môi) để tính toán sự biến động về khoảng cách, góc nghiêng của các thớ cơ khi người học thay đổi biểu cảm. [5]



Hình 4: Minh họa Đặc trưng hình học dựa trên Landmark.

2. **Mẫu nhị phân cục bộ (LBP):** Thuật toán mã hóa kết cấu bề mặt da bằng cách so sánh độ sáng giữa điểm ảnh trung tâm với các điểm lân cận, giúp AI phát hiện được các nếp nhăn biểu cảm nhỏ (như nếp nhăn giữa trán khi bối rối). [6]

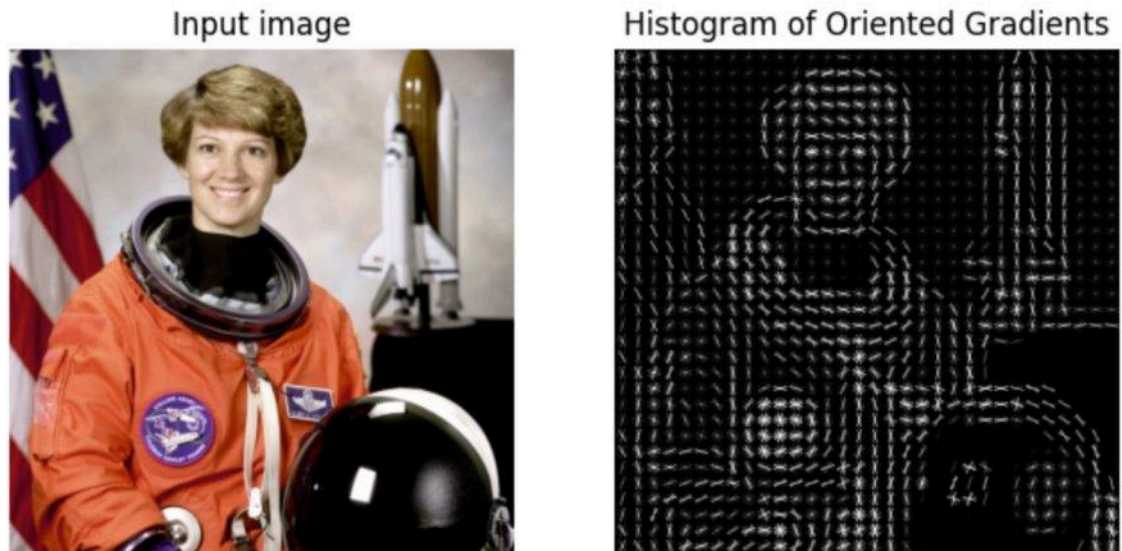
Huấn luyện bộ kiểm tra với LBP



- ❑ Xét ảnh 20×20 : độ phân giải chuẩn
- ❑ Chia ảnh 20×20 thành 9 vùng chồng lấp kích thước 10×10 pixels (kích thước chồng lấp = 5 pixels).
- ❑ Mỗi vùng, tính histogram 16-bin histogram sử dụng $LBP_{4,1}$, kết hợp các histogram đơn được histogram 144 – bin.
- ❑ Áp dụng $LBP_{8,1}^{u2}$ lên ảnh 20×20 tính được histogram 59 – bin.
- ❑ Kết hợp với 144 bins đã tính $\rightarrow$ được histogram $144 + 59 = 203$ bin biểu diễn khuôn mặt


Hình 5: Minh họa Mẫu nhị phân cục bộ (LBP).

3. **Lược đồ định hướng Gradient (HOG):** Phương pháp đo lường hướng và cường độ thay đổi độ sáng của điểm ảnh nhằm bắt trọn hình dáng, các đường biên và góc cạnh nổi bật của các bộ phận như khớp miệng hay chân mày. [7]



Hình 6: Minh họa Lược đồ định hướng Gradient (HOG).

4. **Đặc trưng Haar-like (Viola-Jones):** Sử dụng các khối chữ nhật sáng - tối liên kề để tính toán chênh lệch độ sáng, thường được ứng dụng để phát hiện và định vị nhanh vị trí khuôn mặt trong ảnh thô đầu vào. [8]




Hình 7: Minh họa Đặc trưng Haar-like.

2.3. Các bộ phân lớp học máy cổ điển


Sau khi trích xuất được vector đặc trưng từ giai đoạn trước, dữ liệu này sẽ được đưa vào các thuật toán học máy cổ điển để gán nhãn cảm xúc. Hai thuật toán phổ biến nhất bao gồm:

1. **Máy vector hỗ trợ (Support Vector Machine - SVM):** Thuật toán hoạt động bằng cách tìm một đường ranh giới tối ưu (siêu phẳng phân tách) để phân chia không gian dữ liệu thành các vùng rõ ràng, đại diện cho từng lớp cảm xúc khác nhau (vui, buồn, tức giận...). [9]



Hình 8: Minh họa Máy vector hỗ trợ (Support Vector Machine - SVM)

2. **Rừng ngẫu nhiên (Random Forest):** Thuật toán sử dụng một tập hợp gồm rất nhiều "cây quyết định" hoạt động độc lập. Mỗi cây sẽ tự đưa ra các câu hỏi lựa chọn về đặc trưng khuôn mặt, sau đó toàn bộ hệ thống sẽ tiến hành bỏ phiếu theo số đông để đưa ra nhãn cảm xúc cuối cùng. [10]



Hình 9: Minh họa Rừng ngẫu nhiên (Random Forest)

2.4. Phân tích ưu và nhược điểm hệ thống truyền thống

Khi so sánh với các phương pháp học sâu hiện đại, phương pháp truyền thống bộc lộ rõ những đặc tính sau:

2.4.1. Ưu điểm

- **Trực quan và rõ ràng:** Các đặc trưng hình học hay kết cấu đa đều dựa trên các công thức toán học tường minh, giúp con người dễ dàng hiểu được tại sao AI lại đưa ra kết quả đó (tính giải thích được cao).

2.4.2. Nhược điểm

- **Kém ổn định trước biến động môi trường:** Do các đặc trưng được thiết kế cứng bằng tay, hệ thống cực kỳ nhạy cảm với sự thay đổi của ánh sáng hoặc góc quay. Chỉ cần học sinh ngồi lệch đèn, bật đèn bàn học một bên hoặc hơi nghiêng đầu quá 30 độ, các con số tính toán khoảng cách Landmark hay mã hóa kết cấu LBP sẽ bị sai lệch hoàn toàn, khiến SVM phân loại sai hoàn toàn.
- **Khó cá nhân hóa:** Rất khó xây dựng được một bộ quy tắc thủ công bao quát được sự khác biệt bẩm sinh trên gương mặt của hàng trăm học sinh khác nhau (ví dụ có bạn bẩm sinh mắt híp, hay có bạn khóe miệng trễ xuống dễ bị nhận nhầm là đang buồn ngủ hoặc buồn chán).


CHƯƠNG 3: CÁC PHƯƠNG PHÁP HỌC SÂU HIỆN ĐẠI

CHƯƠNG 3: CÁC PHƯƠNG PHÁP HỌC SÂU HIỆN ĐẠI (DEEP LEARNING APPROACH)

3.1. Sự chuyển dịch sang mô hình Học sâu (Deep Learning)

Bước vào kỷ nguyên hiện đại, sự bùng nổ của Học sâu (Deep Learning) đã thay đổi hoàn toàn cách tiếp cận bài toán Nhận dạng Cảm xúc Khuôn mặt (FER). Thay vì chia làm hai giai đoạn độc lập và phụ thuộc vào các đặc trưng thủ công như phương pháp truyền thống, học sâu sử dụng mô hình học từ đầu đến cuối (End-to-End Learning).

[Ảnh Khuôn Mặt Thô] → [Mạng Nơ-ron Học Sâu (EfficientNet)] → [Nhãn Cảm Xúc]



Hình 10: Minh họa mô hình Học sâu (Deep Learning)

3.1.1. Tại sao Học sâu không cần trích chọn đặc trưng thủ công?

Trong các phương pháp truyền thống, con người phải tự nghĩ ra các công thức để đo khoảng cách mắt, miệng hoặc mã hóa nếp nhăn. Phương pháp này rất dễ bỏ sót các chi tiết quan trọng và cực kỳ nhạy cảm với ánh sáng hay góc chụp.

Học sâu giải quyết vấn đề này bằng cách cho phép mạng nơ-ron tự học hỏi từ hàng trăm nghìn bức ảnh mẫu. Hệ thống hoạt động theo cơ chế **Học đặc trưng đa cấp (Multi-level Feature Learning)**:


- **Các lớp đầu tiên (Lớp nông):** Tự động phát hiện các đặc trưng hình học cơ bản như đường biên, góc cạnh, các nét sáng tối thô trên mặt.
- **Các lớp tiếp theo (Lớp trung gian):** Kết hợp các đường nét thô để tạo thành cấu trúc bộ phận hoàn chỉnh như hình dáng mắt, sống mũi, khóe môi.
- **Các lớp cuối cùng (Lớp sâu):** Tổng hợp thông tin của toàn bộ gương mặt để rút ra các đặc trưng ngữ nghĩa trừu tượng thể hiện các biểu cảm phức tạp (như sự co giãn đồng thời của cơ má và cơ khóe mắt khi cười).

Nhờ cơ chế tự học này, mô hình học sâu có khả năng thích nghi cực kỳ cao trước các biến động của môi trường thực tế – điều mà các phương pháp truyền thống hoàn toàn bất khả thi.

3.2. Nguyên lý hoạt động trực quan của mạng CNN trong bài toán FER

Một mạng CNN tiêu chuẩn cho tác vụ nhận dạng cảm xúc khuôn mặt bao gồm bốn bước xử lý cơ bản: Lớp tích chập (Convolution), Hàm kích hoạt (Activation), Lớp gộp (Pooling) và Lớp kết nối đầy đủ (Fully Connected) đưa ra xác suất. [11]

Ảnh Mặt Thô→[Lớp Tích Chập]→[Hàm Kích Hoạt ReLU]→[Lớp Gộp]→[Lớp Kết Nối Đầy Đủ]→Cảm xúc



Hình 11: Minh họa Cấu trúc của CNN

3.2.1. Phép toán tích chập (Convolution)

- Quét tìm đặc trưng

Lớp tích chập là thành phần cốt lõi thực hiện nhiệm vụ trích xuất đặc trưng không gian của khuôn mặt. Thay vì nhìn vào toàn bộ bức ảnh một cách đại khái, máy tính sử dụng các **bộ lọc nhỏ (kernels/filters)** trượt tuần tự qua từng vùng của bức ảnh (giống như ta cầm kính lúp quét qua bản đồ).

Tại mỗi điểm dừng, bộ lọc sẽ thực hiện phép nhân tương ứng giữa giá trị điểm ảnh và trọng số của bộ lọc để tính ra độ khớp. Nếu vùng ảnh chứa nét vẽ giống với bộ lọc (ví dụ: một đường cong của nụ cười), kết quả đầu ra (Feature Map) sẽ có giá trị rất cao. [12]


Hình 12: Minh họa Phép toán tích chập (Convolution) - Quét tìm đặc trưng

3.2.2. Hàm kích hoạt ReLU (Activation) - Lọc bỏ nhiễu

Operation	Filter	Convolved Image
Identity	$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	
Edge detection	$\begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$	
	$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$	
	$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$	
Sharpen	$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$	
Box blur (normalized)	$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$	
Gaussian blur (approximation)	$\frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$	

Sau lớp tích chập, dữ liệu được đưa qua hàm kích hoạt **ReLU (Rectified Linear Unit)**. Hàm này hoạt động cực kỳ đơn giản: giữ nguyên các giá trị dương và biến toàn bộ các giá trị âm thành 0 ($f(x) = \max(0, x)$).

Về mặt trực quan biểu cảm, ReLU giúp loại bỏ các thông tin nhiễu, các vùng tối không quan trọng và chỉ giữ lại những vùng cơ mặt được kích hoạt mạnh mẽ (nơi biểu cảm cảm xúc hiển thị rõ nét nhất). [13]




Hình 13: Minh họa hàm kích hoạt ReLU: $f(x) = \max(0, x)$

3.2.3. Phép toán gộp cực đại (Max Pooling) - Thu gọn ảnh

Lớp gộp thực hiện nhiệm vụ thu nhỏ kích thước của bức ảnh đặc trưng nhưng vẫn giữ lại thông tin quan trọng nhất. Phổ biến nhất là **Max Pooling** 2×2 : máy tính chia bức ảnh thành các ô nhỏ kích thước 2×2 pixel và chỉ giữ lại duy nhất điểm có giá trị lớn nhất trong ô đó [14] [16]

Quá trình này mang lại hai lợi ích lớn:


- Giảm kích thước ảnh đi 4 lần, giúp máy tính chạy nhanh hơn rất nhiều.
- Tạo ra **tính bất biến đối với dịch chuyển nhỏ**: dù học sinh có hơi nghiêng đầu hay lệch sang trái/phải một chút, các đặc trưng cảm xúc lớn nhất vẫn được giữ lại đúng vị trí.



Hình 13: Minh họa Phép toán Max Pooling

3.2.4. Lớp kết nối đầy đủ (Fully Connected) và Softmax - Đưa ra dự đoán

Ở cuối mạng nơ-ron, bức ảnh đặc trưng sau khi thu gọn sẽ được duỗi thẳng thành một hàng dọc các con số (vector đặc trưng) và đưa qua lớp kết nối đầy đủ (Fully Connected). Lớp này đóng vai trò giống như một ban giám khảo: kết hợp toàn bộ thông tin về mắt, mũi, miệng để đưa ra điểm số thô cho từng cảm xúc. [15]




Cuối cùng, hàm **Softmax** chuyển đổi các điểm số thô này thành phân phối xác suất từ 0 đến 100% cho 6 loại cảm xúc sao cho tổng xác suất bằng 100% (ví dụ: Happy: 85%, Neutral: 10%, Sad: 5%). [16]

3.3. Kiến trúc EfficientNet và Kỹ thuật Compound Scaling

Kiến trúc EfficientNet (do Google giới thiệu năm 2019) đã giải quyết bài toán tối ưu hiệu năng trên thiết bị cạnh bằng cách đề xuất một phương pháp mở rộng mạng khoa học mang tên Mở rộng hỗn hợp (Compound Scaling).

Thông thường, để nâng cao độ chính xác của một mạng nơ-ron, các kỹ sư thường mở rộng một trong ba chiều kích thước một cách độc lập:

EfficientNet chỉ ra rằng, ba chiều kích thước này có mối quan hệ ràng buộc mật thiết. Nếu độ phân giải ảnh tăng, mạng cần nhiều lớp hơn (sâu hơn) để tăng trường thụ cảm (receptive field), đồng thời cần nhiều kênh hơn (rộng hơn) để ghi nhận nhiều chi tiết hơn [20]:



Chiều mở rộng mạng	Định nghĩa kỹ thuật	Vai trò đối với nhận diện cảm xúc
Chiều sâu (Depth - d)	Tăng số lượng lớp mạng ($d = \alpha^\phi$)	Giúp mô hình học được nhiều đặc trưng biểu cảm cơ bản ở tầng ngữ nghĩa sâu và phức tạp hơn. Nhưng mạng quá sâu dễ bị triệt tiêu đạo hàm và khó huấn luyện.
Chiều rộng (Width - w)	Tăng số lượng kênh đặc trưng ($w = \beta^\phi$)	Tăng số kênh đặc trưng giúp mạng bắt được các chi tiết biểu cảm nhỏ. Nhưng mạng quá rộng nhưng nông sẽ gặp khó khăn trong việc học các đặc trưng ngữ nghĩa mức cao.
Độ phân giải (Resolution - r)	Tăng kích thước ảnh đầu vào ($r = \gamma^\phi$)	Đảm bảo hình ảnh đầu vào sắc nét, không bị vỡ ảnh làm biến dạng các góc mắt hay nếp nhăn. Nhưng lượng tính toán tỉ lệ thuận với bình phương độ phân giải

Compound Scaling	Mở rộng đồng bộ cả 3 chiều	Đạt sự cân bằng tối ưu vượt trội, tiết kiệm tối đa tham số tính toán nhưng độ chính xác cao.
-------------------------	-----------------------------------	--

Tỷ lệ này được ràng buộc bởi công thức toán học tối ưu:

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi$$

Với điều kiện ràng buộc:

$$\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$$

Nhờ sự phối hợp đồng bộ này, mạng EfficientNet đạt được sự cân bằng hoàn hảo giữa độ chính xác phân loại và chi phí tính toán phần cứng.

3.4. Xử lý Temporal (Chuỗi thời gian) trong phân tích video

Khi nhận diện cảm xúc từ webcam thời gian thực, mô hình phân tích độc lập từng khung hình (frame) riêng lẻ. Điều này dẫn đến một vấn đề: hiện tượng nhiễu nháy nhần giữa các khung hình liên tiếp.

Trong môi trường thực tế, webcam của người học thường hoạt động ở tốc độ 30 khung hình/giây. Nếu ta chỉ áp dụng mạng nơ-ron tích chập (CNN) để phân tích độc lập từng khung hình một, hệ thống rất dễ gặp phải hiện tượng nháy nhần. Chỉ cần người học chớp mắt, bóng đổ thay đổi nhẹ hoặc đầu dịch chuyển trong một phần mười giây, mô hình AI có thể nhận diện sai lệch cảm xúc tại khoảnh khắc đó (ví dụ đang từ bình thường nhảy sang buồn, rồi lập tức quay lại bình thường).

Kết quả hiển thị trên màn hình sẽ bị giật cục và thay đổi nhần liên tục, gây khó khăn cho việc thống kê chính xác trạng thái học tập của học sinh.

Để khắc phục hiện tượng trên, các hệ thống FER hiện đại áp dụng bộ lọc làm mịn thời gian. Thay vì đưa ra quyết định cảm xúc dựa trên một khung hình duy nhất, hệ thống sẽ duy trì một bộ đệm trượt lưu giữ kết quả dự đoán của N khung hình gần nhất. Nhần cảm xúc cuối cùng hiển thị cho người học sẽ là trung bình cộng điểm số xác suất hoặc nhần xuất hiện nhiều nhất trong bộ đệm này.

Phương pháp này giúp triệt tiêu các điểm nhiễu tức thời, làm mượt luồng dữ liệu cảm xúc đầu ra và phản ánh đúng hơn diễn tiến tâm lý thực tế của người học.

3.5. So sánh tổng quan giữa phương pháp Truyền thống và Học sâu

Đặc điểm so sánh	Phương pháp truyền thống	Phương pháp học sâu hiện đại

Cách trích chọn đặc trưng	Thủ công (Hand-crafted) qua các công thức toán học (LBP, HOG, Haar).	Tự động học (End-to-End) qua các lớp tích chập của mạng CNN.
Độ ổn định (Robustness)	Kém, nhạy cảm với sự thay đổi của ánh sáng, góc nghiêng mặt hay yếu tố che khuất.	Cao, tự thích nghi tốt trước sự biến động phức tạp của môi trường thực tế.
Độ phức tạp tính toán	Thấp, cấu trúc nông, chạy rất nhẹ trên CPU, bộ nhớ RAM tiêu thụ cực kỳ ít.	Cao, mạng nơ-ron nhiều tầng đòi hỏi tài nguyên tính toán lớn (cần GPU hoặc tối ưu hóa sâu khi chạy CPU).
Tính tường minh (Interpretability)	Cao (Ưu điểm): Các đặc trưng dựa trên hình học (khoảng cách mắt, môi), con người hoàn toàn hiểu được tại sao AI đoán thế.	Thấp (Nhược điểm): Mô hình với hàng triệu phép nhân ma trận phức tạp, con người rất khó chỉ ra chính xác pixel nào quyết định kết quả.
Sự phụ thuộc vào dữ liệu	Thấp (Ưu điểm): Không cần lượng dữ liệu khổng lồ để cấu hình các bộ lọc đặc trưng.	Cực cao (Nhược điểm): Yêu cầu hàng vạn đến hàng triệu ảnh có gán nhãn để huấn luyện mà không bị quá khớp (overfitting).
Khả năng cá nhân hóa	Khó thực hiện do các bộ lọc đặc trưng được thiết kế cứng bằng tay.	Dễ dàng thông qua huấn luyện lại một phần mạng (Fine-tuning) trên tập dữ liệu đích.

Tóm lại, cả hai thể hệ công nghệ đều có những ưu điểm và hạn chế riêng mang tính bổ khuyết cho nhau. Trong khi phương pháp học sâu mang lại độ chính xác vượt trội trước các biến động của môi trường thực tế (ví dụ như e-learning tại nhà), phương pháp truyền thống vẫn giữ giá trị lớn nhờ khả năng vận hành cực kỳ nhẹ nhàng, không yêu cầu phần cứng mạnh và có tính minh bạch cao về mặt toán học.

CHƯƠNG 4: TẬP DỮ LIỆU & KIẾN TRÚC HỆ THỐNG

4.1. Các tập dữ liệu chuẩn trong bài toán FER

4.2. Tập dữ liệu tự thu thập cho người Đông Nam Á

Bộ dữ liệu này được nhóm trích xuất và lọc chọn trực tiếp từ bộ dữ liệu FairFace (tải về từ Hugging Face: HuggingFaceM4/FairFace) [21].

- **Lọc chủng tộc:** Chỉ giữ lại chủng tộc Southeast Asian (SEA) (người Đông Nam Á).
- **Lọc độ tuổi:** Chỉ chọn các ảnh thuộc hai nhóm tuổi 10–19 tuổi và 20–29 tuổi.
- **Cân bằng dữ liệu :** Số lượng ảnh của mỗi lớp về mức đồng đều là 61 ảnh/lớp nhằm tránh hiện tượng mô hình bị lệch sang lớp có nhiều mẫu. Bộ dữ liệu hoàn chỉnh có tổng cộng 366 ảnh chia đều cho 6 lớp cảm xúc: Anger, Disgust, Happiness, Neutral, Sadness, Surprise.

[Models](#)
[Datasets](#)
[Spaces](#)
[Buckets](#)
[Docs](#)
[Enterprise](#)
[Pricing](#)
[Log In](#)
[Sign Up](#)

[Datasets: HuggingFaceM4 / FairFace](#)
like 33
Follow HuggingFaceM4 888

Modality: [Image](#)
Format: [parquet](#)
Size: 100K-1M
Libraries: [Datasets](#) [Dask](#) [Croissant](#)
+1 License: [cc-by-4.0](#)

[Dataset card](#)
[Data Studio](#)
[Files and versions](#)
[Community 1](#)

Dataset Viewer

Auto-converted to Parquet
[API](#)
[Embed](#)
[Duplicate](#)
[Data Studio](#)

Subset (2)
0.25 · 97.7k rows

Split (2)
train · 86.7k rows

Search is not available for this dataset

image	age	gender	race	service_test
Image · width (px)	class label	class label	class label	bool
224 · 224	9 classes	2 classes	7 classes	2 classes
	6 50-59	0 Male	0 East Asian	true
	4 30-39	1 Female	1 Indian	false
	1 3-9	1 Female	2 Black	false

[→ Copy to bucket](#)
[Use this dataset](#)

Downloads last month

2,063

Homepage: [github.com](#)
Repository: [github.com](#)
Paper: [openaccess.thecvf.com](#)

Leaderboard: [Leaderboard](#)
Point of Contact: [Point of Contact](#)
Number of rows: 195,396

Total file size: 2.67 GB

[Models trained or fine-tuned on HuggingFaceM4 / ...](#)

[evaks/fairface-age-detection-model-ca...](#)

4.3. Kiến trúc và quy trình xử lý chi tiết của hệ thống

Hệ thống nhận dạng cảm xúc người học thời gian thực được thiết kế với 5 giai đoạn tuần tự:

1. Webcam
2. Haar Cascade
3. CLAHE
4. EfficientNet
5. Temporal

4.3.1. Giai đoạn 1: Thu nhận luồng hình ảnh và phát hiện khuôn mặt


Hệ thống sử dụng thư viện OpenCV để kết nối với Webcam trực tiếp của người học qua giao thức DirectShow ở độ phân giải 640×480 pixel.

Để tối ưu hóa tài nguyên tính toán (vốn rất giới hạn trên CPU máy tính cá nhân của học sinh), nhóm sử dụng bộ lọc Haar Cascade cổ điển (haarcascade_frontalface_default.xml). Các tham số phát hiện mặt được cấu hình tinh chỉnh như sau:

scaleFactor = 1.1: Ảnh đầu vào được giảm kích thước 10% sau mỗi chu kỳ quét để phát hiện khuôn mặt ở các khoảng cách xa gần khác nhau.

minNeighbors = 5: Một vùng ảnh phải được phát hiện tối thiểu 5 lần bởi các bộ lọc Haar-like lân cận thì mới được coi là khuôn mặt hợp lệ, giúp loại bỏ các hậu cảnh nhiễu.

minSize = (30, 30): Bỏ qua toàn bộ các khuôn mặt quá nhỏ hoặc ở quá xa camera.



```
1 """Camera + capture video"""
2
3 import cv2
4 import numpy as np
5 from typing import Tuple, Optional
6 from src.constants import EMOTION_COLORS
7
8 class CameraCapture:
9     """class quản lý camera"""
10
11     def __init__(self, camera_id: int = 0):
12         self.camera_id = camera_id
13         self.cap = None
14         self.is_opened = False
15
16     def open_camera(self) -> bool:
17         """mở camera, trả về True nếu ok"""
18         # ưu tiên DirectShow (on định hơn MSMF trên Windows)
19         self.cap = cv2.VideoCapture(self.camera_id, cv2.CAP_DSHOW)
20
21         if not self.cap.isOpened():
22             # fallback: thu backend mặc định
23             self.cap = cv2.VideoCapture(self.camera_id)
24
25         if not self.cap.isOpened():
26             print(f" KHÔNG THE MỞ CAMERA ID: {self.camera_id}")
27             return False
28
29         # set resolution 640x480
30         self.cap.set(cv2.CAP_PROP_FRAME_WIDTH, 640)
```

Code thu nhận luồng hình ảnh và phát hiện khuôn mặt của hệ thống


4.3.2. Giai đoạn 2: Tiền xử lý cân bằng sáng thích nghi (CLAHE)

Khuôn mặt sau khi phát hiện và cắt ra dưới dạng vùng ảnh xám thường gặp phải các lỗi về ánh sáng cục bộ như: ngược sáng từ cửa sổ, lóa sáng xanh từ màn hình, hoặc đèn phòng chiếu lệch

một bên. Nếu sử dụng phương pháp cân bằng sáng lược đồ toàn cục các chi tiết sẽ bị cháy sáng hoặc tăng nhiễu hạt ở vùng quá tối.

Nhóm giải quyết bằng cách áp dụng bộ lọc CLAHE (Contrast Limited Adaptive Histogram Equalization) với các tham số:

1. Lưới phân hoạch ảnh: `tileGridSize = (8, 8)`. Ảnh khuôn mặt được chia thành một lưới gồm 64 ô nhỏ kích thước bằng nhau (ví dụ: nếu khuôn mặt có kích thước 160×160 pixel, mỗi ô nhỏ sẽ là 20×20 pixel). Việc cân bằng độ tương phản được thực hiện độc lập trong mỗi ô này để đảm bảo độ sáng phân bố đều cục bộ.
2. Giới hạn độ tương phản: `clipLimit = 2.0`. Lược đồ tần suất của mỗi ô sẽ bị cắt bớt nếu độ tương phản vượt quá 2 lần trung bình, phần dư thừa được phân phối lại đều khắp lược đồ. Cơ chế này giúp tránh việc phóng đại quá mức các điểm nhiễu li ti vốn xuất hiện rất nhiều khi quay trong điều kiện thiếu sáng.
3. Khử răng cưa biên ô: Để tránh hiện tượng đứt gãy độ sáng ở ranh giới giữa các ô, hệ thống sử dụng phép nội suy song tuyến tính (Bilateral/Bilinear Interpolation) để làm mịn các đường biên, tạo ra ảnh khuôn mặt có độ tương phản tự nhiên, làm nổi bật rõ các nếp nhăn biểu cảm (vùng khóe mắt, chân mày) ngay cả trong điều kiện ánh sáng cực đoan.



```
src > emotion_engine.py > EmotionEngine > _load_finetuned_weights
13 class EmotionEngine:
22 def __init__(self, model_name: str = 'enet_b0_8_best_afew',
59     'Surprise': 0.35,
60     'Anger': 0.40,
61     'Neutral': 0.35
62 }
63
64 # 3. CLAHE: cân bằng ánh sáng
65 self.clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8))
66
67 mode = f"Fine-tuned ({weights_path})" if weights_path else "Pretrained goc"
68 print(f" EmotionEngine san sang | Model: {model_name} | Weights: {mode} | Fine-tuned: {self.is_finetuned}")
69
70 def _load_finetuned_weights(self, weights_path: str):
71     """load fine-tuned weights vào model
72
73     Lưu ý: HSEmotionRecognizer thay model.classifier = nn.Identity và
74     lưu classifier_weights/bias dạng numpy riêng.
75     Can update CA model state_dict + numpy classifier.
76     """
77     import os
78     if not os.path.isfile(weights_path):
79         print(f" Không tìm thấy file weights: {weights_path}")
80         print(" Tiếp tục với model gốc (pretrained).")
81         return
82
83     device = 'cuda' if torch.cuda.is_available() else 'cpu'
84     checkpoint = torch.load(weights_path, map_location=device, weights_only=False)
85
86     # 1. load backbone weights vào model
87     self.emotion_recognizer.model.load_state_dict(
88         checkpoint['model_state_dict'], strict=False
89     )
```

Code tiền xử lý cân bằng sáng thích nghi của hệ thống

4.3.3. Giai đoạn 3: Nhận diện cảm xúc bằng mạng EfficientNet-B0

Vùng ảnh khuôn mặt sau khi tiền xử lý CLAHE được đưa qua các bước chuẩn hóa bắt buộc:

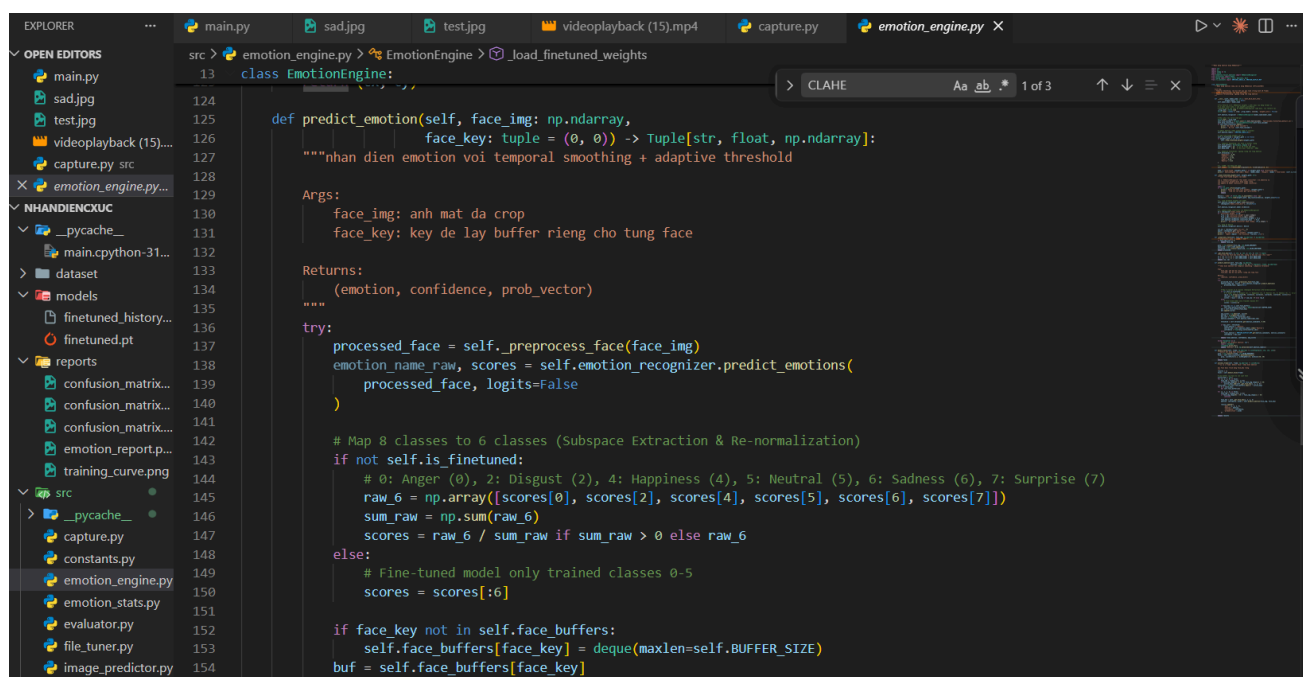
- Chuyển đổi định dạng ảnh từ BGR của OpenCV sang định dạng Tensor trong PyTorch.
- Thay đổi kích thước về kích thước chuẩn của mạng: 224×224 pixel.
- Chuẩn hóa giá trị điểm ảnh về dải phân phối chuẩn của ImageNet với trung bình (mean) là $[0.485, 0.456, 0.406]$ và độ lệch chuẩn (std) là $[0.229, 0.224, 0.225]$. Đây là bộ tham số

chuẩn hóa chuẩn mực của thư viện PyTorch/Torchvision dành cho tất cả các mô hình đã được huấn luyện sẵn.

Sau đó, ảnh được đưa qua mô hình EfficientNet-B0 để trích xuất đặc trưng không gian.

Đối với mô hình gốc (Pretrained - 8 đầu ra): Để so sánh công bằng với mô hình fine-tuned 6 lớp, hệ thống chỉ giữ lại điểm số của 6 lớp tương ứng trong tập hợp {Anger, Disgust, Happiness, Neutral, Sadness, Surprise} bỏ qua nhãn Fear và Contempt. Sau đó, điểm số của 6 nhãn này được chia cho tổng của chính chúng để tổng của 6 nhãn này quy về 100%.

Đối với mô hình Fine-tuned (6 lớp): Do được huấn luyện trực tiếp trên 6 lớp của tập dữ liệu Đông Nam Á, 2 cổng đầu ra cuối cùng của mạng nơ-ron (chỉ số 6 và 7) hoàn toàn bị loại bỏ khỏi mảng dữ liệu (thông qua phép cắt lát mảng `scores[:6]`) trước khi đưa vào các bước tính toán tiếp theo. Vì vậy, trong phân phối xác suất đầu ra cuối cùng của hệ thống, xác suất của 2 lớp này ngầm định bằng 0.



```
EXPLORER
main.py
sad.jpg
test.jpg
videoplayback (15)...
capture.py src
emotion_engine.py
NHANDIENXUC
__pycache__
main.python-31...
dataset
models
finetuned_history...
finetuned.pt
reports
confusion_matrix...
confusion_matrix...
confusion_matrix...
emotion_report.p...
training_curve.png
src
__pycache__
capture.py
constants.py
emotion_engine.py
emotion_stats.py
evaluator.py
file_tuner.py
image_predictor.py

src > emotion_engine.py > EmotionEngine > _load_finetuned_weights
13 class EmotionEngine:
124
125
126
127
128
129
130
131
132
133
134
135
136
137
138
139
140
141
142
143
144
145
146
147
148
149
150
151
152
153
154

def predict_emotion(self, face_img: np.ndarray,
                    face_key: tuple = (0, 0)) -> Tuple[str, float, np.ndarray]:
    """nhận diện emotion với temporal smoothing + adaptive threshold

    Args:
        face_img: ảnh mặt đã crop
        face_key: key để lấy buffer riêng cho từng face

    Returns:
        (emotion, confidence, prob_vector)
    """
    try:
        processed_face = self._preprocess_face(face_img)
        emotion_name_raw, scores = self.emotion_recognizer.predict_emotions(
            processed_face, logits=False
        )

        # Map 8 classes to 6 classes (Subspace Extraction & Re-normalization)
        if not self.is_finetuned:
            # 0: Anger (0), 2: Disgust (2), 4: Happiness (4), 5: Neutral (5), 6: Sadness (6), 7: Surprise (7)
            raw_6 = np.array([scores[0], scores[2], scores[4], scores[5], scores[6], scores[7]])
            sum_raw = np.sum(raw_6)
            scores = raw_6 / sum_raw if sum_raw > 0 else raw_6
        else:
            # Fine-tuned model only trained classes 0-5
            scores = scores[:6]

        if face_key not in self.face_buffers:
            self.face_buffers[face_key] = deque(maxlen=self.BUFFER_SIZE)
        buf = self.face_buffers[face_key]
```

Code nhận diện cảm xúc bằng mạng EfficientNet-B0

4.3.4. Giai đoạn 4: Bộ lọc làm mịn thời gian (Temporal Smoothing) và Theo dõi tâm khuôn mặt


Để khử hiện tượng nháy nhãn (Flickering), xác suất cảm xúc của khung hình hiện tại được đẩy vào một bộ đệm trượt dạng hàng đợi có kích thước cố định `BUFFER_SIZE = 10` khung hình gần nhất. Điểm số xác suất hiển thị cuối cùng là trung bình cộng của 10 khung hình này.

Cơ chế theo dõi khuôn mặt: Trong bối cảnh thực tế, khung hình webcam có thể xuất hiện nhiều người hoặc khuôn mặt của học sinh di chuyển nhẹ qua lại. Nếu sử dụng chung một bộ đệm cho cả khung hình, dữ liệu sẽ bị trộn lẫn và làm sai lệch bộ đệm làm mịn. Nhóm đã cài đặt giải pháp theo dõi khuôn mặt độc lập:

- Cơ chế lọc và ghi nhận khuôn mặt đại diện: Hệ thống quy ước khuôn mặt đầu tiên phát hiện được (thường là khuôn mặt của học sinh ngồi gần nhất và chính diện camera) là Khuôn mặt

đại diện (Primary Face). Chỉ có dữ liệu cảm xúc của Primary Face mới được ghi nhận vào lịch sử phiên học của SessionStats để vẽ báo cáo cuối buổi. Mọi khuôn mặt phụ xuất hiện ở hậu cảnh (ví dụ: người đi qua lại) sẽ bị tự động lọc bỏ khỏi biểu đồ báo cáo, đảm bảo tính tập trung và chính xác của dữ liệu thống kê.

- Hệ thống tính toán tọa độ tâm của từng bounding box chứa khuôn mặt. Mỗi khuôn mặt được theo dõi qua các khung hình liên tiếp dựa trên khoảng cách tâm. Nhóm đặt ngưỡng GRID_SIZE = 60 pixel. Nếu tâm khuôn mặt ở khung hình mới lệch ít hơn 60 pixel so với khung hình trước, hệ thống xác định đó là cùng một người học và gán đúng bộ đệm tương ứng (face_buffers: Dict[tuple, deque]). Nếu lệch quá 60 pixel hoặc xuất hiện khuôn mặt mới, hệ thống tự động khởi tạo một bộ đệm trống riêng biệt cho khuôn mặt đó. Điều này đảm bảo tính độc lập và chính xác khi làm mịn thời gian cho từng khuôn mặt trong phòng.



```
src > emotion_engine.py > EmotionEngine > predict_emotion
13 class EmotionEngine:
125 def predict_emotion(self, face_img: np.ndarray,
143
144     if not self.is_finetuned:
145         # 0: Anger (0), 2: Disgust (2), 4: Happiness (4), 5: Neutral (5), 6: Sadness (6), 7: Surprise (7)
146         raw_6 = np.array([scores[0], scores[2], scores[4], scores[5], scores[6], scores[7]])
147         sum_raw = np.sum(raw_6)
148         scores = raw_6 / sum_raw if sum_raw > 0 else raw_6
149     else:
150         # Fine-tuned model only trained classes 0-5
151         scores = scores[:6]
152
153     if face_key not in self.face_buffers:
154         self.face_buffers[face_key] = deque(maxlen=self.BUFFER_SIZE)
155     buf = self.face_buffers[face_key]
156     buf.append(scores)
157
158     avg_scores = np.mean(buf, axis=0)
159     max_idx = np.argmax(avg_scores)
160     max_conf = float(avg_scores[max_idx])
161     emotion_candidate = self.emotion_labels[max_idx]
162
163     threshold = self.thresholds.get(emotion_candidate, 0.40)
164
165     if max_conf < threshold:
166         final_emotion = 'Neutral'
167         neutral_idx = self.emotion_labels.index('Neutral')
168         confidence = float(avg_scores[neutral_idx])
169     else:
170         final_emotion = EMOTION_DISPLAY_MAP.get(emotion_candidate, emotion_candidate)
171         confidence = max_conf
172
173     return final_emotion, confidence, avg_scores
```

Code bộ lọc làm mịn thời gian (Temporal Smoothing) và Theo dõi tâm khuôn mặt

4.4. Module thống kê và trực quan hóa cảm xúc

Trong suốt phiên học, tất cả dữ liệu bao gồm: mốc thời gian trôi qua kể từ khi bắt đầu (elapsed_sec), nhãn cảm xúc đã lọc qua ngưỡng thích nghi (emotion), và độ tin cậy (confidence) của khuôn mặt đại diện đầu tiên (Primary Face - khuôn mặt chính diện của học sinh) được lưu trữ trực tiếp vào cấu trúc danh sách trong bộ nhớ RAM (self.history).

Chỉ khi người học kết thúc phiên học (bấm phím q hoặc đóng chương trình), module mới kích hoạt hàm generate_report() để tổng hợp toàn bộ lịch sử và xuất ra một báo cáo đồ họa trực quan dạng bảng điều khiển (Dashboard) sử dụng thư viện Matplotlib


Các thành phần của Dashboard báo cáo cảm xúc (reports/emotion_report.png):

Biểu đồ tròn (Pie Chart): Chiếm vùng không gian phía trên, mô tả tỷ lệ phần trăm phân bố thời gian của từng trạng thái cảm xúc.

Biểu đồ thời gian (Timeline Chart): Chiếm vùng không gian lớn phía dưới. Biểu đồ này kết hợp hai dạng biểu diễn đồ thị:

1. Đồ thị đường bước: Vẽ một đường xám nét đứt kết nối các trạng thái cảm xúc theo dòng thời gian thực, giúp giáo viên dễ dàng theo dõi sự chuyển biến tâm lý của học sinh.
2. Biểu đồ phân tán: Mỗi điểm mốc ghi nhận được vẽ thành một hình tròn màu. Kích thước (size) của hình tròn được lập trình co giãn động theo độ tin cậy của AI:
 $\text{size} = \max(40, \text{confidence} \times 250)$. Điểm tròn càng to chứng tỏ học sinh biểu hiện cảm xúc đó càng rõ nét và độ tin cậy của mô hình AI càng cao.

Khung tóm tắt phiên học (Session Summary Box): Nằm ở dưới cùng của báo cáo, tự động thống kê tổng thời gian học (giờ), tổng số khung hình đã phân tích, tốc độ xử lý trung bình (số khung hình/giây), và số lượng các cảm xúc khác nhau xuất hiện trong phiên học. Báo cáo này được tự động lưu lại dưới dạng file ảnh PNG chất lượng cao tại đường dẫn `reports/emotion_report.png` và đồng thời hiển thị trực quan lên màn hình.



```

16 class SessionStats:
17     def generate_report(self, output_dir: str = 'reports') -> None:
18         # --- 1. PIE CHART ---
19         total_records = len(emotions)
20         wedges, texts, autotexts = ax1.pie(
21             counts,
22             labels=present_emotions,
23             colors=colors_rgb,
24             autopct=lambda p: f'{p:.1f}%\n({int(round(p * total_records / 100))}/{total_records}',
25             startangle=90,
26             textprops={'fontsize': 11},
27             wedgeprops={'edgecolor': 'white', 'linewidth': 1.5}
28         )
29         # Tăng kích cỡ chữ % cho dễ đọc
30         for at in autotexts:
31             at.set_fontsize(10)
32             at.set_fontweight('bold')
33         ax1.set_title('Phân Bố Cảm Xúc (Pie Chart)', fontsize=12, pad=15)
34
35         # --- 2. TIMELINE LINE CHART ---
36         # Step line: thể hiện sự chuyển đổi cảm xúc
37         ax2.step(
38             timestamps, y_vals,
39             where='post', color='gray', alpha=0.5,
40             linewidth=1.5, linestyle='--'
41         )
42
43         # Scatter: mỗi chấm là 1 frame, size = confidence
44         for t, e, c in zip(timestamps, emotions, confidences):
45             idx = emotion_to_idx[e]
46             bgr = EMOTION_COLORS[e]

```

Code module thống kê và trực quan hóa cảm xúc

CHƯƠNG 5: KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

CHƯƠNG 5: KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

5.1. Môi trường cài đặt và tham số thực nghiệm

Tham số thiết lập khi chạy thử nghiệm Fine-tuning:

Phân chia tập dữ liệu: Tập huấn luyện (dataset/train) gồm 366 ảnh, trong đó dùng 85% để huấn luyện (312 ảnh) và 15% để kiểm định (54 ảnh). Tập kiểm tra độc lập (dataset/test_dung1landuynhat) gồm 150 ảnh cân bằng hoàn hảo (25 ảnh cho mỗi lớp).

Tham số tối ưu: Thuật toán Adam, Learning Rate bằng 10^{-4} (nhỏ nhằm giữ lại các đặc trưng tốt đã học của mô hình gốc).

Chiến lược đóng băng: Đóng băng toàn bộ các lớp của mạng (backbone), chỉ cho phép huấn luyện lại lớp phân loại (Classifier) để thích nghi với dữ liệu mới và ngăn ngừa quá khớp (Linear Probing).

Số lượng Epochs: 15 epochs với Batch Size bằng 16.

5.2. Các độ đo đánh giá hiệu năng

Thông được đánh giá bằng các chỉ số toán học chuẩn trong phân loại:

TP (True Positive - Dương tính thật): Số lượng mẫu cảm xúc X được mô hình dự đoán chính xác là X.

FP (False Positive - Dương tính giả / Báo động nhầm): Số lượng mẫu cảm xúc khác bị mô hình dự đoán nhầm thành cảm xúc X.

FN (False Negative - Báo sót / Bỏ sót): Số lượng mẫu cảm xúc X bị mô hình dự đoán sai thành cảm xúc khác.

TN (True Negative - Âm tính thật): Số lượng mẫu cảm xúc khác được mô hình dự đoán chính xác không phải là cảm xúc X.

Accuracy (Độ chính xác toàn cục): Tỷ lệ phần trăm tổng số ảnh đoán đúng trên tổng số ảnh kiểm tra. Chỉ số này cho thấy hiệu năng tổng quát của hệ thống trên toàn bộ tập dữ liệu =

$$\frac{TP + TN}{TP + FP + FN + TN}$$

Precision (Độ chính xác chi tiết / Khả năng tránh nhận nhầm): Tỷ lệ phần trăm số ảnh thực sự là cảm xúc X trong tổng số ảnh mà mô hình đã dự đoán là X. Chỉ số này càng cao chứng tỏ hệ thống càng ít bị báo động giả (không bị nhận nhầm khi học sinh đang có nét mặt bình thường) = $\frac{TP}{TP + FP}$

Recall (Độ nhạy / Khả năng tránh bỏ sót): Tỷ lệ phần trăm số ảnh cảm xúc X được mô hình nhận diện đúng trên tổng số ảnh thực tế ngoài đời có cảm xúc X. Chỉ số này càng cao chứng tỏ hệ thống càng ít bỏ sót cảm xúc của người học = $\frac{TP}{TP + FN}$

F1-Score (Điểm F1): Giá trị trung bình điều hòa (Harmonic Mean) giữa Precision và Recall.

F1-Score đóng vai trò là một thước đo cân bằng, phản ánh khách quan hiệu năng của mô hình khi có sự đánh đổi giữa Precision và Recall = $2 \times \frac{Precision \times Recall}{Precision + Recall}$

Support: Số lượng mẫu ảnh thực tế thuộc mỗi lớp cảm xúc có trong tập kiểm tra (Test Set).

Macro Average : Trung bình cộng đơn giản của các chỉ số (Precision, Recall, F1-Score) trên tất cả các lớp cảm xúc, coi trọng vai trò của mọi lớp cảm xúc ngang nhau mà không phụ thuộc vào kích thước mẫu của mỗi lớp.

5.3. Kết quả thực nghiệm và so sánh

Sau khi chạy thử nghiệm đánh giá độc lập trên tập dữ liệu kiểm tra độc lập (dataset/test_dung1landuynhat gồm 150 ảnh hoàn toàn mới), nhóm thu được kết quả so sánh trực tiếp như sau:

Độ chính xác của Mô hình gốc (HSEmotion Pretrained): 78.0%


Độ chính xác của Mô hình Fine-tuned: 79.3% (Cải tiến tăng +1.3%)

Để đánh giá mô hình gốc (vốn đầu ra có 8 lớp cảm xúc) trên tập kiểm tra 6 lớp một cách công bằng khi 2 cổng cảm xúc đầu ra không liên quan (Fear, Contempt) được loại bỏ, hệ thống chỉ trích xuất logits của 6 cảm xúc mục tiêu và tái cấu trúc lại phân phối xác suất Softmax về mức 100% trước khi tính toán các chỉ số Precision, Recall và F1-Score.

Dưới đây là Báo cáo phân loại chi tiết (Classification Report) của cả hai mô hình trên tập dữ liệu kiểm tra độc lập:


Báo cáo phân loại của Mô hình gốc (HSEmotion Pretrained)

Cảm xúc	Precision	Recall	F1-score	Support
Anger	0.96	0.96	0.96	25
Disgust	0.81	0.52	0.63	25
Happiness	0.92	0.96	0.94	25
Neutral	0.53	0.64	0.58	25
Sadness	0.69	0.80	0.74	25
Surprise	0.83	0.80	0.82	25
Accuracy	-	-	0.78	150
Macro avg	0.79	0.78	0.78	150



Báo cáo phân loại của Mô hình Fine-tuned (Linear Probing)

Cảm xúc	Precision	Recall	F1-score	Support
Anger	0.92	0.88	0.90	25
Disgust	0.85	0.68	0.76	25
Happiness	0.78	1.00	0.88	25
Neutral	0.60	0.60	0.60	25
Sadness	0.72	0.84	0.78	25
Surprise	0.95	0.76	0.84	25
Accuracy	-	-	0.79	150
Macro avg	0.80	0.79	0.79	150



5.4. Phân tích và thảo luận kết quả thực nghiệm

Kết quả thực nghiệm cho thấy: Mô hình Fine-tuned đạt hiệu năng vượt trội hơn mô hình gốc với độ chính xác 79.3% so với 78.0% (tăng +1.3%) trên tập dữ liệu test độc lập 150 ảnh

1. Khắc phục giới hạn kích thước dữ liệu:

Bản chất cấu trúc mô hình Mạng nơ-ron EfficientNet-B0 gồm hai phần chính: Backbone (bộ trích xuất đặc trưng) chiếm 99% tham số bộ não mô hình, chịu trách nhiệm nhận diện các đường nét cơ mặt (mắt, khóe miệng, chân mày) và đã được huấn luyện sẵn trên 450.000 ảnh chuẩn của AffectNet; và Classifier (lớp phân loại cuối cùng) chịu trách nhiệm đưa ra quyết định cảm xúc dựa trên đặc trưng do Backbone truyền sang.

Do tập huấn luyện tự thu thập khá nhỏ (366 ảnh), nếu cho phép cập nhật toàn bộ mạng nơ-ron sâu, mô hình sẽ cố sửa đổi hàng triệu tham số để khớp tuyệt đối với 366 ảnh này, dẫn đến hiện tượng overfitting — học thuộc lòng tập train nhưng đoán sai khi gặp tập test.

Giải pháp: Nhóm sử dụng phương pháp Linear Probing bằng cách khóa cứng (đóng băng) toàn bộ Backbone để giữ nguyên kinh nghiệm nhận diện cơ mặt từ 450.000 ảnh chuẩn gốc, và chỉ mở khóa

duy nhất lớp Classifier cuối cùng để học cách ánh xạ sang 6 lớp cảm xúc mới. Nhờ đó, mô hình tránh được hiện tượng overfitting và giữ nguyên khả năng tổng quát hóa mạnh mẽ.

2. Khả năng nhận diện nổi bật theo lớp so với mô hình gốc dựa trên tập test

Happiness (Vui vẻ): Đạt độ nhạy (Recall) tuyệt đối (1.00) vì cười là biểu cảm rất đặc trưng và dễ nhận biết nhất.

Disgust (Ghê tởm): Đạt điểm F1 tốt (0.76) - tăng +13% F1-Score so với mô hình gốc (0.63) nhờ được ánh xạ và chuẩn hóa nhãn tương thích một cách chính xác giữa bộ trọng số pretrained gốc và tập dữ liệu mới.

Sadness (Buồn bã): F1-Score tăng từ 0.74 lên 0.78 (+4%), Precision tăng từ 0.69 lên 0.72 (+3%) và Recall tăng từ 0.80 lên 0.84 (+4%), cho thấy mô hình sau tinh chỉnh ít bị đoán nhầm cảm xúc buồn của người học.

Surprise (Ngạc nhiên): F1-Score tăng từ 0.82 lên 0.84 (+2%), đặc biệt Precision tăng từ 0.83 lên 0.95 (+12%) thể hiện khả năng lọc nhiễu nhận nhầm ngạc nhiên rất tốt.

Neutral (Bình thường): F1-Score tăng từ 0.58 lên 0.60 (+2%), Precision tăng từ 0.53 lên 0.60 (+7%).

Anger (Tức giận): Mô hình gốc vốn đã nhận diện lớp này rất xuất sắc với F1-Score 0.96. Đây là kết quả của việc tối ưu hóa hàm mất mát toàn cục (global loss function) trên toàn bộ 6 lớp cảm xúc, trong đó mô hình điều chỉnh các ranh giới phân loại để nâng cao hiệu năng tổng thể trên các lớp có độ chính xác thấp (như Disgust và Sadness).

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Tóm tắt kết quả đạt được

Thông qua bài tập lớn này, nhóm đã hoàn thành các mục tiêu đề ra:

1. Tìm hiểu sâu sắc lý thuyết về bài toán nhận dạng cảm xúc khuôn mặt (FER), từ các phương pháp trích chọn đặc trưng thủ công truyền thống đến các mô hình học sâu hiện đại.
2. Xây dựng thành công một chương trình demo nhận dạng cảm xúc thời gian thực từ Webcam hoạt động mượt mà trên CPU máy tính cá nhân phổ thông.
3. Tích hợp các giải pháp hỗ trợ thực tế như bộ lọc CLAHE để xử lý ánh sáng không đều, thuật toán Temporal Smoothing để khử hiện tượng nháy nhần, và cơ chế ngưỡng thích nghi Adaptive Thresholds cho từng loại cảm xúc.
4. Thực hiện thử nghiệm huấn luyện (Fine-tuning) và đánh giá, rút ra những kết luận thực nghiệm có giá trị về mối quan hệ giữa kích thước tập dữ liệu huấn luyện và hiệu năng của các mô hình học sâu.

6.2. Những hạn chế của hệ thống

Mặc dù đạt được những kết quả khả quan, hệ thống vẫn tồn tại một số hạn chế:

1. Kích thước dữ liệu huấn luyện nhỏ: Khiến mô hình Fine-tuned chưa thể vượt trội hơn mô hình gốc (hiện tại đạt hiệu năng ngang bằng nhau ở mức 78.7%).
2. Độ ổn định của Haar Cascade: Thuật toán phát hiện mặt Haar Cascade đôi khi bị mất dấu khuôn mặt nếu người học quay nghiêng đầu quá sâu hoặc đưa tay lên che mặt.
3. Chưa đánh giá trên diện rộng: Hệ thống mới được thử nghiệm trên webcam các cá nhân trong nhóm, ảnh và video đơn lẻ, chưa tích hợp trên một lớp học online để đánh giá độ trễ đường truyền và khả năng chịu tải.

TAI LIEU THAM KHAO

TÀI LIỆU THAM KHẢO

- [1] Technical University of Munich (TUM), "Face Recognition," TUM collab wiki. [Online]. Available: <https://collab.dvb.bayern/spaces/TUMlfdv/pages/69119928/Face+Recognition> [Accessed: May 21, 2024].
- [2] WHAT ARE EMOTIONS?
<https://www.paulekman.com/universal-emotions/>
- [3] LCANet: a model for analysis of students real-time sentiment by integrating attention mechanism and joint loss function (Pengyun Hu, Xianpiao Tang, Liu Yang, Chuijian Kong & Daoxun Xia)
<https://link.springer.com/article/10.1007/s40747-024-01608-8/figures/1>
- [4] Deep Learning vs. Traditional Computer Vision (Niall O' Mahony, Sean Campbell, Anderson Carvalho, Suman Harapanahalli, Gustavo Velasco Hernandez, Lenka Krpalkova, Daniel Riordan, Joseph Walsh)
https://www.researchgate.net/publication/336915128_Deep_Learning_vs_Traditional_Computer_Vision
- [5] Face landmark detection guide (Google for Developers)
https://developers.google.com/edge/mediapipe/solutions/vision/face_landmarker
- [6] Mẫu nhậ phân cục bộ - Trí tuệ nhân tạo - Nhận dạng
<https://www.youtube.com/watch?v=95KEdVY2EzA>
- [7] Histogram of Oriented Gradients
<https://www.geeksforgeeks.org/computer-vision/histogram-of-oriented-gradients/>
- [8] A comparative study between LBP and Haar-like features for Face Detection using OpenCV
https://www.researchgate.net/publication/308836179_A_comparative_study_between_LBP_and_Haar-like_features_for_Face_Detection_using_OpenCV
- [9] Giới thiệu về Support Vector Machine (SVM)
<https://viblo.asia/p/gioi-thieu-ve-support-vector-machine-svm-6J3ZgPVEImB>
- [10] What is random forest?
<https://www.ibm.com/think/topics/random-forest>
- [11] Convolutional Neural Networks (CNN) trong Deep Learning
<https://aicandy.vn/convolutional-neural-networks-cnn-trong-deep-learning/>
- [12] [Deep Learning] Tìm hiểu về mạng tích chậ (CNN)
<https://viblo.asia/p/deep-learning-tim-hieu-ve-mang-tich-chap-cnn-maGK73bOKj2>
- [13] TẠI SAO LẠI SỬ DỤNG ACTIVATION FUNCTION TRONG NEURAL NETWORK
<https://viblo.asia/p/tai-sao-lai-su-dung-activation-function-trong-neural-network-MG24BwweJz3>
- [14] Mạng Nơ-ron Tích chậ (Convolutional Neural Network - CNN)
<https://viblo.asia/p/mang-no-ron-tich-chap-convolutional-neural-network-cnn-PoL7eQv64vk>
- [15] Tìm hiểu về Convolutional Neural Network và làm một ví dụ nhỏ về phân loại ảnh
<https://viblo.asia/p/tim-hieu-ve-convolutional-neural-network-va-lam-mot-vi-du-nho-ve-phan-loai-anh-aWj53WXo56m>
- [16] Convolutional Neural Network (CNN): A Complete Guide
<https://learnopencv.com/understanding-convolutional-neural-networks-cnn/>
- [17] Deploy ứng dụng Machine learning lên Web server. Phần 7: Ứng dụng CNN trong nhậ diện cảm xúc
<https://viblo.asia/p/deploy-ung-dung-machine-learning-len-web-server-phan-7-ung-dung-cnn-trong-nhan-dien-cam-xuc-maGK7mxAlj2>

[18] Comparison between ResNet and EfficientNet for Image Classification – An Analytical Study of Performance and Efficiency

https://www.researchgate.net/publication/398250815_Comparison_between_ResNet_and_EfficientNet_for_Image_Classification_-_An_Analytical_Study_of_Performance_and_Efficiency

y

[19] Convolutional Neural Network (CNN) in Deep Learning

<https://www.geeksforgeeks.org/deep-learning/convolutional-neural-network-cnn-in-machine-learning/>

[20] EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks

<https://research.google/pubs/efficientnet-rethinking-model-scaling-for-convolutional-neural-networks/>

[21] FairFace Dataset

<https://huggingface.co/datasets/HuggingFaceM4/FairFace>